



ALMA MATER STUDIORUM
UNIVERSITÀ DI BOLOGNA

Progetto del corso

INTRODUZIONE AL PENSIERO COMPUTAZIONALE E ALLA DATA SCIENCE

Francesco Poggi - francesco.poggi5@unibo.it

Dipartimento di Scienze Politiche e Sociali

Alma Mater Studiorum Università di Bologna

Il progetto di fine corso

L'obiettivo del progetto è realizzare un'analisi di un dataset con le tecniche e le tecnologie presentate in questo corso.

Il punto fondamentale non è solo “allenare un modello”, ma sviluppare un piccolo progetto di data science riproducibile e documentato.

Quindi il progetto dovrà integrare questi elementi:

- analisi dati;
- machine learning;
- GitHub;
- LaTeX/Overleaf;
- interpretazione critica dei risultati.

Il tema dell'analisi, i requisiti da rispettare e le modalità di consegna verranno descritti nelle prossime slide.



Organizzazione dei team

Tutti gli studenti si dividono in team composti **da due o tre persone**.

- il **lavoro** è stato **tarato** per un gruppo di queste dimensioni
- gruppi di dimensione diversa devono essere autorizzati dal docente (scrivete un email motivando la richiesta)

I **team si registrano** compilando il seguente **foglio Google**:

https://docs.google.com/spreadsheets/d/1WCxFw_zBwQ43ET3oKSahq8Xlc-V_Acoz4E6uI1WIFOwM/edit?usp=sharing

Dovete inserire cognome, nome, matricola e un numero progressivo che identifica il vostro gruppo.



Organizzazione dei team

- Ogni team **consegna e discute** il progetto **insieme** (anche qui, non ci sono eccezioni!).
- Alla discussione del progetto il team dichiara in anticipo la natura del contributo di ciascun membro oppure accetta che chiunque sia interrogato (e nel dettaglio) su tutto il progetto.
- Il sottoscritto NON è coinvolto nell'organizzazione dei team.



Organizzazione dei team

Non accetterò progetti chiaramente incompleti o non corretti:

- in questo caso dovreste completare il lavoro/correggere gli errori e ritornare a discuterlo in seguito.

I progetti sufficienti porteranno a valutazioni (ossia voti) individuali, ad esempio:

1. progetto buono - valutazione membri del team:

studente 1: voto 28

studente 2: voto 24

1. progetto sufficiente - valutazione membri del team:

studente 1: voto 22

studente 2: voto 14

studente 3: voto 22

Più dettagli sulle valutazioni in seguito...



Il progetto

Il progetto si articola idealmente in sei fasi principali:

1. setup del progetto e del repository GitHub
2. descrizione e comprensione del dataset
3. analisi esplorativa e visualizzazione
4. modellazione
5. valutazione e interpretazione dei risultati
6. report scientifico in LaTeX



Dataset e obiettivi (goal)

Potrete scegliere di svolgere l'analisi scegliendo fra una serie di dataset:

Dataset	Goal
Credit_Card_Default	previsione dell'insolvenza creditizia
Employee_Attrition	previsione dell'abbandono dei dipendenti
Online_Shoppers	previsione dell'acquisto online
Bank_Marketing	previsione della sottoscrizione
Customer_Churn	previsione dell'abbandono del servizio

I dataset verranno forniti insieme al materiale del progetto (es. queste slide).



Nota importante

Come per il progetto di Laboratorio, i dataset e gli eventuali file di accompagnamento con una breve descrizione dei campi sono gli unici dati che vi verranno forniti.

Alcuni aspetti di questi dati potrebbero essere di difficile interpretazione, poco chiari oppure ambigui.

Questa situazione è molto comune per i dati scientist: sta a voi identificare problemi (se presenti), analizzarli, formulare ipotesi e fornire un'interpretazione o una spiegazione ragionevole.



Fase 1 - Setup del progetto e del repository GitHub

Premessa: un progetto di data science non è solo codice finale, ma include:

- pianificazione;
- documentazione;
- motivazioni delle scelte;
- evoluzione del lavoro;
- riproducibilità.

Aggettivi chiave di progetto: **organizzato, riproducibile, documentato, tracciabile.**

In pratica è utile tracciare:

- cosa è stato fatto;
- chi lo ha fatto;
- perché è stato fatto;
- come è cambiato il progetto;
- quali decisioni sono state prese.



Fase 1 - Setup del progetto e del repository GitHub

Obiettivo: impostare un progetto organizzato e riproducibile.

Repository GitHub con struttura tipo:

```
/
|— data/
|— notebooks/
|— figures/
|— report/
|— README.md
```



Fase 1 - Setup del progetto e del repository GitHub

File **README.md** **obbligatorio** con informazioni generali di progetto.

Ad esempio (lista non esaustiva):

- descrizione progetto;
- descrizione dataset;
- obiettivo;
- modelli usati;
- istruzioni per l'esecuzione;
- membri gruppo.



Fase 1 - Setup del progetto e del repository GitHub

Requisiti:

- almeno 10 commit;
- messaggi significativi;
- almeno un branch per membro;
- almeno un merge.



Fase 2 - Descrizione e comprensione del dataset

Obiettivo: prima analisi del dataset per comprenderne:

- struttura;
- distribuzioni;
- qualità;
- limiti;
- possibili problemi.



Fase 2 - Descrizione e comprensione del dataset

Requisiti - almeno:

- 8 domande/ipotesi;
- 5 statistiche descrittive;
- 3 riflessioni critiche sui dati.

Esempi:

- class imbalance;
- outlier;
- feature correlate;
- dati mancanti;
- feature sospette.



Fase 3 - Analisi esplorativa e visualizzazione

Obiettivo: capire (e comunicare) relazioni tra feature - fra di loro, ed in particolare rispetto al target.

Requisiti - almeno:

- 4 grafici diversi;
- 4 domande/ipotesi;
- 2 confronti tra variabili/gruppi/classi.

Cercate di usare gli strumenti che abbiamo affrontato (scatterplot, boxplot, heatmap, barplot, ecc.).

Opzionalmente: guardate le gallerie di grafici forniti dalla libreria seaborn (es. [1]) e valutate di introdurre alcuni di questi se utile.

[1] <https://seaborn.pydata.org/examples/index.html>



Fase 4 - Modellazione

Obiettivo: confrontare modelli diversi.

Requisiti - almeno:

- 3 modelli diversi;
- di questi, se possibile, usate almeno 1 modello lineare (es. regressione) e 1 modello non lineare (es. k-NN, Random Forest).

Nota: a differenza del progetto di laboratorio, dovete svolgere voi le operazioni richieste per preparare i dataset per la classificazione, ad esempio:

- train/test split
- conversione variabili categoriche in numeriche



Fase 5 - Valutazione e interpretazione dei risultati

Obiettivo: valutazione critica dei risultati

Requisiti - per OGNI modello:

- accuracy;
- confusion matrix;
- precision;
- recall;
- f1-score.



Fase 5 - Valutazione e interpretazione dei risultati

Esempi di riflessioni:

- punti di forza;
- limiti;
- interpretabilità;
- tipo di errori;
- costo computazionale.

Altri **possibili approfondimenti**:

- feature importance (RF);
- coefficienti (regressione logistica).



Fase 6 - Report scientifico in LaTeX

Obiettivo: scrivere un mini report tecnico/scientifico.

Lunghezza indicativa: 6 pagine

Requisiti pt. 1/3: caricare su GitHub sia il PDF finale, che tutti i sorgenti Overleaf (file + cartelle).

Ad esempio, se su Overleaf avete questi file e cartelle:

`images/immagine1.png`

`images/immagine2.jpg`

`bibliography.bbl`

`relazione.tex`

Dovete caricare nella cartella report/ su GitHub questi file e cartelle, più il PDF finale.



Fase 6 - Report scientifico in LaTeX

Requisiti pt. 2/3: il documento **deve** essere strutturato. Possibili sezioni:

- Introduzione
- Dataset
- Metodologia
- Risultati
- Discussione
- Conclusioni

Requisiti pt. 3/3 - elementi obbligatori:

- figure (almeno 2)
- tabelle (almeno 1)
- formule (almeno 1)
- bibliografia
- link repository GitHub



Requisiti e valutazione

I **requisiti minimi** appena specificati servono per darvi un'**indicazione** della **quantità di lavoro** da svolgere.

I requisiti devono essere **rispettati e sono sufficienti per** raggiungere la **votazione massima**:

- es. un progetto con il doppio delle domande e dei modelli ma di bassa qualità può ricevere un voto molto inferiore ad uno che soddisfa i requisiti minimi ma è svolto molto bene, ed è preciso, chiaro e sintetico
- se lo ritenete opportuno potete realizzare più analisi e modelli, ma fatelo se questo è utile e interessante, e se non vi porta a sacrificare il rigore dell'analisi, la chiarezza e la sinteticità



Requisiti e valutazione

Tutti i gruppi rispettano questi requisiti, indipendentemente dal numero di membri.

Solo nel caso di **gruppi da tre** consiglio di valutare di inserire qualche domanda/ipotesi e modello in aggiunta, per dare la possibilità a tutti in fase di discussione di dimostrare il proprio contributo

- anche in questo caso vale la regola di prima: potete raggiungere alla votazione massima senza farlo, e non dovete sacrificare il rigore dell'analisi, la chiarezza e la sinteticità



Criteri di valutazione

Oltre alla qualità dei risultati (ad esempio in termini di accuratezza, precision e recall) verrà valutata la **qualità del lavoro svolto** (compreso repository GitHub e relazione)

Concentratevi quindi su:

- organizzare e documentare bene il lavoro usando GitHub
- svolgere un'analisi attenta facendo domande e ipotesi interessanti procedendo in maniera rigorosa e precisa, fornendo spiegazioni chiare e sintetiche
- scrivere una relazione chiara e sintetica



Criteri di valutazione

E' più importante presentare un'analisi di qualità che dimostri che:

- sapete **svolgere un'analisi** da Data Scientist padroneggiando gli argomenti affrontati durante il corso
- avete le **competenze tecniche** per svolgere le analisi (con Python e le sue librerie, GitHub, LaTeX e gli altri strumenti presentati)
- sapete **capire e spiegare in maniera chiara i risultati** delle vostre analisi

piuttosto che raggiungere performance ottime in maniera casuale e/o confusa.



Indicazioni

Alcune indicazioni valide per tutto il progetto:

- **giustificate sempre le vostre osservazioni con i dati:** ad esempio, se scrivete che le prenotazioni sono equamente distribuite nel corso dell'anno dovete mostrare i dati che supportano questa affermazione (es. la media di prenotazioni mese per mese).
- uno **schema tipico da usare** è il seguente:
 - esposizione della domanda/ipotesi/aspetto che si intende analizzare
 - l'informazione viene recuperata e mostrata tramite un procedimento di manipolazione dei dati (es. filtro più calcolo del valore medio)
 - risposta alla domanda/conclusione/riflessione/analisi sulla base dell'informazione recuperata
- **siate sintetici**



Uso di assistenti - es. LLM

È consentito usare LLM come assistenti alla programmazione.

Nel caso decideste di farlo dovete:

1. documentare **dove** li avete usati (es. nel notebook e/o nella relazione) e **in che modo**
2. **comprendere il codice prodotto**, e quindi saperlo interpretare e commentare: questo verrà verificato in fase di discussione orale

Il progetto è comunque pensato per essere svolto senza ricorrere a questi assistenti: durante il corso vi sono stati forniti gli strumenti pratici necessari per realizzare autonomamente tutte le fasi del lavoro.



Il lavoro di team

- Tutti i membri dei team sono tenuti a lavorare e lavorare insieme.
- È meglio essere parte attiva di un progetto mediocre che passiva di un progetto meraviglioso.
- Mi riservo all'esame di scoprire il contributo individuale di ciascuno, indipendentemente dalla bontà del progetto consegnato.



Scadenze

Durante l'anno sarà possibile consegnare e discutere i progetti in corrispondenza di ogni appello d'esame (sei in tutto).

Tipicamente la discussione avviene dopo circa una settimana dalla consegna, in modo che io abbia il tempo di visionare i progetti.



Scadenze

Le **date** di consegna e di discussione **definitive verranno comunicate** con un annuncio dal docente.

Per la sessione estiva 2026, le **date indicative** sono:

	CONSEGNA	DISCUSSIONE
Scadenza #1	17/6/2025	24/6/2026
Scadenza #2	1/7/2026	8/7/2026
Scadenza #3	(da definire - 15/7/2026?)	(da definire - 22/7/2026?)

I calendari delle discussioni verranno comunicati dopo le scadenze delle consegne quando saprò quanti progetti dovranno essere discussi.



Scadenze

MOLTO IMPORTANTE:

Questo progetto potrà essere presentato e discusso entro fine 2027.

Chi non avrà discusso entro questa data dovrà presentare il progetto dell'anno in corso.



Materiale del progetto

Il docente fornisce il seguente materiale:

- le slide con le specifiche di progetto
- i dataset e file con la descrizione delle variabili

Il materiale è disponibile sul sito del corso (ossia nella pagina su virtuale.unibo.it).



Materiale del progetto

Segnalo inoltre le seguenti **guide** che spiegano la **sintassi di Colab**, utile per realizzare grassetto, corsivo, elenchi, tabelle ed altri effetti grafici:

- https://colab.research.google.com/notebooks/markdown_guide.ipynb
- https://sourceforge.net/nf/markdown_syntax
- <https://colab.research.google.com/github/gitedio/examples/blob/master/Working%20With%20Markdown%20Cells.ipynb>



Consegna del progetto

I progetti dovranno essere consegnati entro le scadenze scelte inviando un **email al docente** come segue:

- **soggetto:** consegna progetto Introduzione Data Science - [numero-team]
- **corpo:** deve specificare il nome del team, i membri del gruppo e il link al repository GitHub che contiene tutto il materiale del progetto



Consegna del progetto

Due punti IMPORTANTI:

1. il notebook finale che caricate su GitHub deve avere **eseguite tutte le celle di codice** (es. grafici generati ed altri dati mostrati), in modo che il docente possa analizzare i risultati senza rieseguire il notebook
2. è assolutamente **VIETATO MODIFICARE il repository DOPO LA SCADENZA**. Nel caso vi foste dimenticati qualcosa scrivetemi prima di procedere.

Gli studenti che non rispetteranno questi requisiti verranno penalizzati.





ALMA MATER STUDIORUM
UNIVERSITÀ DI BOLOGNA

Grazie per l'attenzione!

Domande?